



머신러닝 고급




1. AI 개념과 용어의 이해



1. AI vs 머신러닝 vs 딥러닝

◆ AI vs 머신러닝 vs 딥러닝



1. AI vs 머신러닝 vs 딥러닝

◆ AI vs 머신러닝 vs 딥러닝

구분	내용
Artificial Intelligence	감지, 추론, 행동 및 적응할 수 있는 프로그램
Machine Learning	데이터가 축적될 수록 성능이 향상되는 알고리즘
Deep Learning	머신러닝의 일부로써 방대한 양의 데이터로부터 다층 신경망으로 학습하는 알고리즘

1. AI vs 머신러닝 vs 딥러닝

◆ AI

- ✓ AI는 기계가 인간의 인지 기능을 모방하는 것
- ✓ 특정 상황에서 기계에게 특정 방식으로 행동하도록 지시하는 프로그램 된 규칙
- ✓ 여러 if-else문은 사람이 프로그래밍한 간단한 규칙

```
if something_is_in_the_way is True:  
    stop_moving()  
else:  
    continue_moving()
```


1. AI vs 머신러닝 vs 딥러닝

◆ AI

- ✓ 1956년의 연구 분야로 결정됨 (존 매카시, 다트머스 대학교)


이 연구는 원칙적으로 학습의 모든 측면 또는 지능의 다른 모든 특징을 정확하게 기술하여 시뮬레이션하는 기계를 만들 수 있다는 추측을 기반으로 진행됩니다. 기계가 언어를 사용하고, 추상화와 개념을 형성하고, 현재 인간에게만 국한된 문제를 해결하고, 스스로를 개선하는 방법을 찾으려고 노력할 것입니다. 신중하게 선택된 과학자 그룹이 여름 동안 함께 작업하면 이런 문제 중 하나 이상에서 상당한 발전을 이룰 수 있다고 생각합니다.

1. AI vs 머신러닝 vs 딥러닝

◆ AI

- ✓ 1956년의 연구 분야로 결정됨 (존 매카시, 다트머스 대학교)
- ✓ 보통의 사람이 수행하는 지능적인 작업을 자동화하기 위한 연구 활동
 - AI는 머신 러닝과 딥러닝을 포괄하는 종합적인 분야
- ✓ 1980년대 까지 '학습'을 언급하지 않음
- ✓ Symbolic AI의 지배적인 패러다임 (1950년대 ~ 1980년대)
 - 프로그래머들이 명시적인 규칙을 충분하게 많이 만들고, DB에 저장된 지식을 다루면 AI라고 생각
 - 전문가 시스템(Expert System)의 호황으로 인기가 절정에 다다름

1. AI vs 머신러닝 vs 딥러닝



1. AI vs 머신러닝 vs 딥러닝

◆ AI


- ✓ 1956년의 연구 분야로 결정됨 (존 매카시, 다트머스 대학교)
- ✓ 보통의 사람이 수행하는 지능적인 작업을 자동화하기 위한 연구 활동
 - AI는 머신 러닝과 딥러닝을 포괄하는 종합적인 분야
- ✓ 1980년대 까지 '학습'을 언급하지 않음
- ✓ Symbolic AI의 지배적인 패러다임 (1950년대 ~ 1980년대)
 - 프로그래머들이 명시적인 규칙을 충분하게 많이 만들고, DB에 저장된 지식을 다루면 AI라고 생각
 - 전문가 시스템(Expert System)의 호황으로 인기가 절정에 다다름
- ✓ 체스 게임처럼 잘 정의된 논리적인 문제를 푸는 데 적합한 것은 증명됨
 - 불분명한 문제를 해결하기 위한 명확한 규칙을 찾는 것은 어려움

1. AI vs 머신러닝 vs 딥러닝

이미지, 음성인식, etc

불분명한 문제 해결 위해 명확한 규칙 찾기 어려움



1. AI vs 머신러닝 vs 딥러닝



1. AI vs 머신러닝 vs 딥러닝

◆ 머신러닝 (기계학습)



- ✓ 데이터 분석, 학습, 학습된 통찰력을 기반으로 정보에 입각한 결정을 내리는 일련의 알고리즘
- ✓ (1950년) 앨런 튜링의 제안



1. AI vs 머신러닝 vs 딥러닝

◆ 머신러닝 (기계학습)

- ✓ 데이터 분석, 학습, 학습된 통찰력을 기반으로 정보에 입각한 결정을 내리는 일련의 알고리즘
- ✓ (1950년) 앨런 튜링의 제안
- ✓ 머신러닝 시스템은 프로그래밍화 되는 것이 아니라 훈련(Training) 되는 것을 의미




1. AI vs 머신러닝 vs 딥러닝

◆ 머신러닝 (기계학습)

- ✓ 일반적인 정의 (아서 새뮤얼, 1959)

머신러닝은 명시적인 프로그래밍 없이 컴퓨터가 학습하는 능력을 갖추게 하는 연구 분야




1. AI vs 머신러닝 vs 딥러닝

◆ 머신러닝 (기계학습)

- ✓ 공학적인 정의 (토미 미첼, 1959)

어떤 작업 T 에 대한 컴퓨터 프로그램의 성능을 P 로 측정했을 때 경험 E 로 인해 성능이 향상되었다면, 이 컴퓨터 프로그램은 작업 T 와 성능 측정 P 에 대해 경험 E 로 학습한 것이다.




1. AI vs 머신러닝 vs 딥러닝

◆ 머신러닝의 주요 구분 - 확률적 모델링 Probabilistic Modeling

- ✓ 통계학 이론을 데이터 분석에 응용
- ✓ 대표적 알고리즘 : Naive Bayes Algorithm
 - 입력 데이터의 특성이 모두 독립적이라고 가정
 - 베이지 정리 Bayes' Theorem를 적용 (베이지 정리와 통계의 토대는 18세기까지 거슬러 올라감)

$$P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

$$Posterior = \frac{Prior \times Likelihood}{Evidence}$$



1. AI vs 머신러닝 vs 딥러닝

◆ 머신러닝의 주요 구분 - 확률적 모델링 Probabilistic Modeling

- ✓ 베이지 정리 : 조건부 확률을 사용하여 분류
- ✓ 독립 가정 : 각 특성은 독립적으로 클래스 분류에 기여
- ✓ 과정


$$P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

- 사전확률 Prior Probability : 각 클래스의 기본 확률 계산
- 가능도 Likelihood : 각 클래스가 주어진 특성을 가질 확률 계산
- 사후확률 Posterior Probability : 입력 데이터가 각 클래스에 속할 확률 계산
- 예측 : 가장 높은 사후 확률을 가지는 클래스를 선택

1. AI vs 머신러닝 vs 딥러닝

◆ 머신러닝의 주요 구분 - 확률적 모델링 Probabilistic Modeling

- ✓ 통계학 이론을 데이터 분석에 응용
- ✓ 대표적 알고리즘 : Logistic Regression



1. AI vs 머신러닝 vs 딥러닝


◆ 머신러닝의 주요 구분 - 확률적 모델링 Probabilistic Modeling

- ✓ 통계학 이론을 데이터 분석에 응용
- ✓ 대표적 알고리즘 : Logistic Regression
 - 하나 이상의 독립변수가 종속변수에 영향을 미치는 데이터셋을 분석하는 통계적 방법
 - 결과 변수는 이진 변수 (0/1, 참/거짓, 예/아니오)
 - 핵심 개념
 - Logit Function : 예측 변수의 선형 결합을 확률로 변환

$$\text{logit}(p) = \ln \left(\frac{p}{1-p} \right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k$$

- Sigmoid Function : Logit을 확률로 변환

$$p = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k)}}$$



1. AI vs 머신러닝 vs 딥러닝

◆ 머신러닝의 주요 구분 - 커널 방법^{Kernel Method}

- ✓ 1990년대 초, 신경망 대신 가장 인기가 많았던 머신러닝 방법
- ✓ 대표적 알고리즘 : Support Vector Machine (SVM)
 - 가장 현대적인 SVM의 공식 (1995년 개발, 벨 연구소 블라드미르 바프닉, 코리나 코르테스)



Vladimir Vapnik




Corinna Cortes

1. AI vs 머신러닝 vs 딥러닝

◆ 머신러닝의 주요 구분 - 커널 방법 Kernel Method

- ✓ 1990년대 초, 신경망 대신 가장 인기가 많았던 머신러닝 방법
- ✓ 대표적 알고리즘 : Support Vector Machine (SVM)
 - 가장 현대적인 SVM의 공식 (1995년 개발, 벨 연구소 블라드미르 바프닉, 코리나 코르테스)



CREATED BY CHAT GPT

1. AI vs 머신러닝 vs 딥러닝

◆ 머신러닝의 주요 구분 - 커널 방법^{Kernel Method}

✓ 대표적 알고리즘 : Support Vector Machine (SVM)

- 데이터 포인트들을 가능한 넓은 마진을 가진 초평면(Hyperplane)으로 나누는 것을 목표

✓ 핵심 개념

▪ 초평면(Hyperplane)

- 데이터 포인트를 분리하는 경계
- 차원이 n 인 공간에서 $n - 1$ 차원의 평면

▪ 서포트 벡터 (Support Vector)

- 초평면과 가장 가까운 데이터 포인트
- 이 포인트들이 결정 경계를 정의하고, 마진을 최대화하는 데 사용됨


▪ 마진(Margin)

- 서포트 벡터와 초평면 사이의 거리
- 마진이 최대가 되도록 초평면을 설정함

1. AI vs 머신러닝 vs 딥러닝

◆ 머신러닝의 주요 구분 - 커널 방법 Kernel Method


✓ 대표적 알고리즘 : Support Vector Machine (SVM)



1. AI vs 머신러닝 vs 딥러닝

◆ 머신러닝의 주요 구분 - 결정 트리^{Decision Tree}


- ✓ 대표적 알고리즘 : Random Forest, Gradient Boosting
- ✓ FlowChart와 같은 구조로 이루어짐
- ✓ 여러 선택지에서 나오는 다양한 결과 보여주기
- ✓ 주요 구성 요소
 - Root Node : 초기 결정 지점
 - Internal Nodes : 중간 결정 지점
 - Branches : 각 노드의 결정 결과를 나타냄
 - Leaf Nodes : 최종 결과나 결정을 나타냄



1. AI vs 머신러닝 vs 딥러닝

◆ Why Machine Learning

- ✓ 전통적인 접근 방법
 - 1단계 : 문제 연구
 - 2단계 : 규칙 작성
 - 3단계 : 평가
 - 충분한 성능이 나올 때까지 1단계-3단계 반복




문제가 어렵고, 규칙이 길어질수록 유지 보수하기 매우 힘들어짐

1. AI vs 머신러닝 vs 딥러닝

◆ Why Machine Learning

✓ 전통적인 접근 방법




1. AI vs 머신러닝 vs 딥러닝


◆ Why Machine Learning

✓ 전통적인 접근 방법

- 1단계 : 문제 연구
- 2단계 : 규칙 작성
- 3단계 : 평가
- 충분한 성능이 나올 때까지 1단계-3단계 반복



문제가 어렵고, 규칙이 길어질수록 유지 보수하기 매우 힘들어짐



1. AI vs 머신러닝 vs 딥러닝

◆ Why Machine Learning




✓ 머신러닝 기법

- 1단계 : 문제 연구
- 2단계 : 머신러닝 모델 훈련
- 3단계 : 평가
- 4단계 : 배포
- 5단계 : 데이터 업데이트와 동시에 2단계 수행

1. AI vs 머신러닝 vs 딥러닝

◆ Why Machine Learning

✓ 머신러닝 기법



1. AI vs 머신러닝 vs 딥러닝

◆ Why Machine Learning?

✓ 머신러닝 기법 적용이 뛰어난 분야

- 기존 솔루션으로는 많은 수동 조정과 규칙이 필요한 문제
⇒ ML모델이 코드를 간단하게 만들고 전통적인 방법보다 더 잘 수행
- 전통적인 방식으로는 해결 방법이 없는 복잡한 문제
⇒ 가장 뛰어난 머신러닝 기법으로 해결 방법을 찾을 수 있음
- 유동적인 환경
⇒ ML 시스템은 새로운 데이터로 쉽게 재훈련할 수 있어 항상 최신 상태를 유지
- 복잡한 문제와 대량의 데이터에서 인사이트 얻기

1. AI vs 머신러닝 vs 딥러닝

◆ Deep Learning

- ✓ 수많은 발명품은 자연 상태를 모방함
 - 사람이 새를 보고 비행기에 대한 영감을 얻음
 - 지능적인 기계를 만들기 → 뇌 구조를 살펴보기 → 인공 신경망(Artificial Neural Network)
- ✓ 인공 신경망은 뉴런의 네트워크에서 영감을 받은 머신러닝 모델이며
- ✓ Deep Learning의 핵심
- ✓ 사용 예시
 - 수백만 개의 이미지 분류
 - 음성 인식 서비스의 성능을 향상
 - 수억 명에 이르는 사용자에게 가장 좋은 비디오 추천

1. AI vs 머신러닝 vs 딥러닝

◆ 머신러닝(ML)과 딥러닝(DL)의 차이 : 사람의 개입 여부

✓ ML


- 사람이 먼저 컴퓨터에 특정 패턴을 추출하는 방법 지시
- 컴퓨터가 스스로 데이터의 특징을 분석하고 축적
- 이렇게 축적된 데이터를 바탕으로 문제를 해결하도록 시스템화

✓ DL

- 사람이 하던 패턴 추출 작업 생략
- 컴퓨터가 스스로 데이터를 기반으로 학습할 수 있도록 정해진 신경망을 컴퓨터에게 줌
- 어린아이가 학습하는 것처럼 경험 중심으로 학습을 수행함

1. AI vs 머신러닝 vs 딥러닝

◆ 머신러닝(ML)과 딥러닝(DL)의 차이 : 사람의 개입 여부




Singh, A.K.; Ganapathysubramanian, B.; Sarkar, S.; Singh, A. Deep Learning for Plant Stress Phenotyping: Trends and Future Perspectives. Trends Plant Sci. 2018, 23, 883–898.

2. 머신러닝과 딥러닝의 주요 개념과 용어

◆ 머신러닝 시스템의 종류 - 지도 학습 Supervised Learning


- ✓ 알고리즘에 주입하는 훈련 데이터에 레이블(Label)이라는 원하는 답이 포함됨
- ✓ 분류 Classification와 회귀 Regression가 전형적인 지도 학습 작업
 - 그림 예시 : 스팸 분류를 위한 레이블된 훈련 세트(지도 학습의 예)



2. 머신러닝과 딥러닝의 주요 개념과 용어

◆ 머신러닝 시스템의 종류 - 지도 학습 Supervised Learning



- ✓ 알고리즘에 주입하는 훈련 데이터에 레이블(Label)이라는 원하는 답이 포함됨
- ✓ 분류 Classification와 회귀 Regression가 전형적인 지도 학습 작업
 - 그림 예시 : 주어진 입력 특성으로 값을 예측 (지도 학습의 예)



2. 머신러닝과 딥러닝의 주요 개념과 용어

◆ 머신러닝 시스템의 종류 - 비지도 학습^{Unsupervised Learning}

- ✓ 훈련 데이터에 레이블이 없으며 시스템이 아무런 도움 없이 학습해야 함
- ✓ 블로그 방문자를 그룹화 (군집^{Clustering})



2. 머신러닝과 딥러닝의 주요 개념과 용어

◆ 머신러닝 시스템의 종류 - 비지도 학습 Unsupervised Learning

✓ 시각화 Visualization

- 레이블이 없는 대규모의 고차원 데이터를 넣으면 도식화가 가능한 2D나 3D 표현을 만들어줌
- 이런 알고리즘은 가능한 한 구조를 그대로 유지


✓ 차원 축소 Dimensionality Reduction

- 데이터 간소화 : 여러 상관관계가 있는 여러 특성을 하나로 합치는 것
- 특성 추출 Feature Extraction : 차의 주행 거리 + 연식 $\Rightarrow$ 두 특성을 차의 마모

2. 머신러닝과 딥러닝의 주요 개념과 용어

◆ 머신러닝 시스템의 종류 - 비지도 학습 Unsupervised Learning

- ✓ t-SNE 시각화 : 의미 있는 군집을 강조



2. 머신러닝과 딥러닝의 주요 개념과 용어

◆ 머신러닝 시스템의 종류 - 비지도 학습 Unsupervised Learning

✓ 이상치 탐지 Outlier Detection

- 부정 거래를 막기 위해 이상한 신용카드 거래 감지
- 제조 결함 잡아내기
- 학습 알고리즘에 주입하기 전에 전체 데이터셋에서 이상한 것을 자동으로 제거
- 새로운 샘플을 보고 정상 데이터인지 아닌지 확인


✓ 특이치 탐지 Novelty Detection : 훈련 세트에 있는 모든 샘플과 달라 보이는 새로운 샘플 탐지

- 강아지 사진 수천장, 늑대 사진 1%라면, 이상치 탐지 알고리즘으로 늑대 사진을 이상치로 분류

2. 머신러닝과 딥러닝의 주요 개념과 용어

◆ 머신러닝 시스템의 종류 - 비지도 학습 Unsupervised Learning

- ✓ 이상치 탐지 Outlier Detection



2. 머신러닝과 딥러닝의 주요 개념과 용어

◆ 머신러닝 시스템의 종류 - 준지도 학습 Semi-Supervised Learning

- ✓ 레이블이 없는 샘플이 다수, 레이블이 있는 샘플 적은 경우
- ✓ 지도학습 + 비지도 학습의 조합
- ✓ 예시
 - 군집 알고리즘을 사용해 비슷한 샘플을 한 그룹으로 모음
 - 레이블이 없는 샘플에 클러스터에서 가장 많이 등장하는 레이블 할당
 - 전체 데이터셋에 레이블이 부여되면 지도 학습 알고리즘을 사용

2. 머신러닝과 딥러닝의 주요 개념과 용어

◆ 머신러닝 시스템의 종류 - 자기 지도 학습^{Self-Supervised Learning}

✓ 레이블이 전혀 없는 데이터셋에서 레이블이 완전히 부여된 데이터셋 생성

✓ 예시

- 레이블이 없는 이미지로 구성된 대량의 데이터셋
- 각 이미지의 일부분을 랜덤하게 마스킹
- 모델이 원본 이미지 복원할 수 있도록 훈련
- 마스킹된 이미지는 모델의 입력
- 원본 이미지는 모델의 레이블로 사용
- [그림] 왼쪽 입력, 오른쪽 타깃




2. 머신러닝과 딥러닝의 주요 개념과 용어

◆ 머신러닝 시스템의 종류 - 강화 학습^{Reinforcement Learning}


- ✓ 에이전트^{Agent} : 학습하는 시스템
- ✓ 환경^{Environment}을 관찰해서 행동^{Action}을 실행하고 그 결과로 보상^{Reward} or 벌점^{Penalty}
- ✓ 시간이 지나면서 가장 큰 보상을 얻기 위해 정책^{Policy}이라고 부르는 최상의 전략 학습
- ✓ 예시
 - 보행 로봇
 - 딥마인드^{DeepMind}의 알파고 프로그램^{AlphaGo}도 강화 학습의 좋은 예
 - 알파고는 수백만 개의 게임을 분석해서 승리 전략 학습
 - 자기 자신과 많은 게임 진행

2. 머신러닝과 딥러닝의 주요 개념과 용어

◆ 머신러닝 시스템의 종류 - 강화 학습 Reinforcement Learning



- 1 관찰
- 2 정책에 따라 행동을 선택



- 3 행동 실행!
- 4 보상이나 벌점을 받음



- 5 정책 수정(학습 단계)
- 6 최적의 정책을 찾을 때까지 반복

2. 머신러닝과 딥러닝의 주요 개념과 용어

◆ 머신러닝 시스템의 종류 - 배치 학습 Batch Learning

✓ 오프라인 학습 Offline Learning

- 시스템이 점진적으로 학습할 수 없음
- 가능한 데이터를 모두 사용해 훈련
- 많은 시간과 자원 필요
- 학습한 것을 단지 적용만 함



모델 성능 감소 ↓↓

2. 머신러닝과 딥러닝의 주요 개념과 용어


◆ 머신러닝 시스템의 종류 - 배치 학습 Batch Learning

- ✓ 모델 부패 Model rot or 데이터 드리프트 Data Drift
 - 모델의 성능은 시간이 지남에 따라 천천히 감소하는 경향
- ✓ 해결 방안
 - 최신 데이터에서 모델을 정기적으로 재훈련하는 것
 - 모델 교체 주기는 각 산업 도메인마다 다 다름
- ✓ 학습 방법
 - 새로운 데이터 + 이전 데이터도 포함
 - 새로운 버전을 처음부터 다시 재 훈련해야 함
 - 이전 모델을 새 모델로 교체
 - 24시간 마다 또는 매주마다 시스템 훈련 필요

2. 머신러닝과 딥러닝의 주요 개념과 용어

◆ 머신러닝 시스템의 종류 - 온라인 학습^{Online Learning}

- ✓ 데이터를 순차적으로 한 개씩 또는 미니배치^{Mini-Batch}라 부르는 작은 묶음 단위로 주입
- ✓ 매 학습 단계가 빠르고 비용이 적게 들어 시스템은 데이터가 도착하는 대로 즉시 학습




2. 머신러닝과 딥러닝의 주요 개념과 용어

- ◆ 머신러닝 시스템의 종류 - 온라인 학습^{Online Learning}
 - ✓ 데이터를 순차적으로 한 개씩 또는 미니배치^{Mini-Batch}라 부르는 작은 묶음 단위로 주입
 - ✓ 매 학습 단계가 빠르고 비용이 적게 들어 시스템은 데이터가 도착하는 대로 즉시 학습
 - ✓ 극도로 빠른 변화에 적응해야 하는 시스템에 적합
 - ✓ 온라인 학습을 사용한 대량의 데이터 처리

2. 머신러닝과 딥러닝의 주요 개념과 용어

◆ 머신러닝 시스템의 종류 - 온라인 학습 Online Learning

- ✓ 온라인 학습을 사용한 대량의 데이터 처리




2. 머신러닝과 딥러닝의 주요 개념과 용어

- ◆ 머신러닝 시스템의 종류 - 온라인 학습Online Learning
 - ✓ 온라인 학습을 사용한 대량의 데이터 처리
 - ✓ 가장 큰 문제점 : 나쁜 데이터가 주입되었을 때 시스템 성능 감소
 - 시스템 면밀히 모니터링 필요
 - 성능 감소가 감지되면 즉각 학습 중지
 - 입력 데이터를 모니터링해서 비정상 데이터를 잡아내기 (이상치 탐지 알고리즘 사용)

2. 머신러닝과 딥러닝의 주요 개념과 용어

◆ 사례 기반 학습 Instance-Based Learning과 모델 기반 학습 Model-Based Learning

- ✓ 일반화 Generalization를 위한 두 가지 접근법 : 사례 기반 학습 & 모델 기반 학습
- ✓ 사례 기반 학습
 - 시스템이 훈련 샘플 기억함으로써 학습



2. 머신러닝과 딥러닝의 주요 개념과 용어

◆ 머신러닝의 주요 도전 과제로 살펴보는 주요 용어

✓ 주요 도전 과제 : 대표성 없는 훈련 데이터

주요 용어	설명
샘플링 잡음Sampling Noise	• (샘플이 작을 때) 우연에 의한 대표성 없는 데이터
샘플링 편향Sampling Bias	• 매우 큰 샘플도 표본 추출 방법이 잘못되면 대표성을 띠지 못함

2. 머신러닝과 딥러닝의 주요 개념과 용어

◆ 머신러닝의 주요 도전 과제로 살펴보는 주요 용어

- ✓ 주요 도전 과제 : 대표성 없는 훈련 데이터
- ✓ 비응답 편향 Nonresponse Bias

아마도 샘플링 편향에 대한 가장 유명한 사례는 랜던 Randon과 루스벨트 Roosevelt가 경쟁했던 1936년 미국 대통령 선거에서 『The Literary Digest』 잡지사가 천만 명에게 우편물을 보내 수행한 대규모 여론 조사일 것입니다. 240만 명의 응답을 받았고, 랜던이 선거에서 57%의 득표율을 얻을 것이라고 높은 신뢰도로 예측했습니다.

하지만 루스벨트가 62%의 득표율로 당선되었습니다. 문제는 『The Literary Digest』의 샘플링 방법에 있었습니다.

- 첫째, 여론 조사용 주소를 얻기 위해 전화번호부, 자사의 구독자 명부, 클럽 회원 명부 등을 사용했습니다. 이런 명부는 모두 공화당(랜던)에 투표할 가능성이 높은 부유한 계층에 편중된 경향이 있습니다.
- 둘째, 우편물 수신자 중 25% 미만의 사람이 응답했습니다. 이 역시 정치에 관심 없는 사람, 『The Literary Digest』를 싫어하는 사람과 다른 중요한 그룹을 제외시켜 표본을 편향되게 만들었습니다. 특히 이러한 종류의 샘플링 편향을 **비응답 편향** nonresponse bias이라고 합니다.

2. 머신러닝과 딥러닝의 주요 개념과 용어

◆ 머신러닝의 주요 도전 과제로 살펴보는 주요 용어


- ✓ 주요 도전 과제 : 관련 없는 특성
- ✓ 성공적인 ML 프로젝트의 핵심 요소 : 훈련에 사용할 좋은 특성 찾기

주요 용어	설명
특성 선택Feature Selection	• 가지고 있는 특성 중에서 훈련에 가장 유용한 특성 선택
특성 추출Feature Extraction	• 특성 결합하여 더 유용한 특성 만들기 (예: 차원 축소 알고리즘)
데이터 수집	• 새로운 데이터를 수집해 새 특성 만들기

2. 머신러닝과 딥러닝의 주요 개념과 용어

◆ 머신러닝의 주요 도전 과제로 살펴보는 주요 용어

- ✓ 주요 도전 과제 : 훈련 데이터 과대적합^{Overfitting}
- ✓ 훈련 데이터에는 너무 잘 맞지만 일반성이 떨어진다는 뜻
- ✓ [그림] 훈련 데이터에 과대적합된 사례



2. 머신러닝과 딥러닝의 주요 개념과 용어


◆ 머신러닝의 주요 도전 과제로 살펴보는 주요 용어

- ✓ 주요 도전 과제 : 훈련 데이터 과대적합^{Overfitting}
- ✓ 원인 : 훈련 데이터의 양과 잡음에 비해 모델이 너무 복잡할 때 일어남
- ✓ 해결 방안
 - 파라미터 수가 적은 모델 선택(고차원 다항 모델보다 선형 모델),
 - 훈련 데이터에 있는 특성 수 줄이기
 - 모델에 제약(=규제)를 가하여 단순화 하기
 - 훈련 데이터를 더 많이 모으기
 - 훈련 데이터의 잡음 줄이기 (오류 데이터 수정 및 이상치 제거)

2. 머신러닝과 딥러닝의 주요 개념과 용어

◆ 머신러닝의 주요 도전 과제로 살펴보는 주요 용어

- ✓ 주요 도전 과제 : 훈련 데이터 과대적합^{Overfitting}
- ✓ 원인 : 훈련 데이터의 양과 잡음에 비해 모델이 너무 복잡할 때 일어남
- ✓ 해결 방안
 - 모델에 제약(=규제)를 가하여 단순화 하기




2. 머신러닝과 딥러닝의 주요 개념과 용어

◆ 머신러닝의 주요 도전 과제로 살펴보는 주요 용어

- ✓ 주요 도전 과제 : 훈련 데이터 과소적합^{Underfitting}
- ✓ 모델이 너무 단순해서 데이터의 내재된 구조를 학습하지 못함
- ✓ 해결 방안
 - 모델 파라미터가 더 많은 강력한 모델 선택
 - 학습 알고리즘에 더 좋은 특성 제공(=특성공학)
 - 모델의 제약 줄이기(=하이퍼파라미터 감소)

2. 머신러닝의 주요 개념





1. Regression

◆ 돈이 사람을 행복하게 만드는가?


- ✓ 데이터 출처 : <https://www.oecdbetterlifeindex.org/> (더 나은 삶의 지표)
- ✓ 데이터 출처 : <https://ourworldindata.org/> 1인당 GDP 데이터 사용

국가	1인당 GDP(US 달러)	삶의 만족도
튀르키예	28,384	5.5
헝가리	31,008	5.6
프랑스	42,026	6.5
미국	60,236	6.9
뉴질랜드	42,404	7.3
호주	48,698	7.3
덴마크	55,938	7.6



1. Regression

◆ 최적의 모델




$$\text{삶의 만족도} = \theta_0 + \theta_1 \times \text{1인당_GDP}$$

1. Regression

◆ 모델링의 일반적인 과정 살펴보기

- ✓ 데이터 분석
- ✓ 모델 선택
- ✓ 훈련 데이터로 모델 훈련 (비용 함수를 최소화하는 모델 파라미터 찾기)
- ✓ FROM



1. Regression


◆ 테스트와 검증

- ✓ 일반화 : 새로운 샘플에 실제로 적용하여 성능 테스트
- ✓ 첫번째 방법 : 실제 서비스에 모델을 넣고 잘 작동하는지 바로 모니터링
 - 만약, 모델이 아주 나쁘다면...
- ✓ 두번째 방법 : 훈련 세트와 테스트 세트로 나눈 후, 모델 테스트
 - 일반화 오차^{Generalization Error} : 새로운 샘플에 대한 오차 비율
 - 테스트 세트에서 모델을 평가함으로써 일반화 오차에 대한 추정값^{Estimation} 얻을 수 있음

1. Regression

◆ 테스트와 검증

- ✓ 두번째 방법 : 훈련 세트와 테스트 세트로 나눈 후, 모델 테스트
 - 일반화 오차 $\text{Generalization Error}$: 새로운 샘플에 대한 오차 비율
 - 테스트 세트에서 모델을 평가함으로써 일반화 오차에 대한 추정값 Estimation 얻을 수 있음




1. Regression

◆ 테스트와 검증

✓ 홀드아웃 검증 Holdout Validation

- 간단하게 훈련 세트의 일부를 떼어내어 여러 후보 모델을 평가하고 가장 좋은 하나 선택
- 홀드아웃 검증 과정이 끝나면 최선의 모델을 전체 훈련세트에서 다시 훈련하여 최종 모델 만듦




1. Regression

◆ 테스트와 검증

✓ 교차검증 Cross Validation


- ML의 성능을 추정하기 위해 사용되는 통계적 방법
- 모델의 결과가 독립적인 데이터셋에 얼마나 잘 일반화되는지 평가하기 위해 사용
- 모델이 보지 못한 데이터에서도 잘 작동하도록 보장 (과적합 감소)



1. Regression

◆ 회귀의 종류

- ✓ 시나리오 : 캘리포니아의 인구 조사 데이터를 사용해 캘리포니아의 주택 가격 모델 만들기




1. Regression

◆ 회귀의 종류

✓ 문제 정의

- 모델의 출력(예: 주택 가격에 대한 예측)이 여러 가지 다른 신호와 함께 다른 ML 시스템의 입력값
- 다른 ML 시스템은 해당 지역에 투자할 가치가 있는지 결정



1. Regression

◆ 회귀의 종류

✓ 문제 정의

- 모델의 출력(예: 주택 가격에 대한 예측)이 여러 가지 다른 신호와 함께 다른 ML 시스템의 입력값
- 다른 ML 시스템은 해당 지역에 투자할 가치가 있는지 결정
- 구역의 중간 주택 가격을 예측하는 모델 개발


회귀의 종류	내 용
다중 회귀Multiple Regression	예측에 사용할 특성이 여러 개 (구역의 인구, 중간 소득 등)
단변량 회귀Univariate Regression	구역마다 하나의 값을 예측
다변량 회귀Multivariate Regression	구역마다 여러 개의 값을 예측

1. Regression

◆ 실전 예제 주요 확인사항

✓ 계층적 샘플링 Stratified Sampling

- 샘플링 편향 방지 위한 것
- 만약 인구 비율이 남성이 60% vs 여성이 40%라면, 샘플링의 숫자도 이 비율에 근사해야 함




1. Regression

◆ 실전 예제 주요 확인사항

✓ 상관계수 조사하기


- 표준 상관계수 Standard Correlation Coefficient
- 상관계수의 범위는 -1부터 1까지



1. Regression

◆ 실전 예제 주요 확인사항

✓ 상관관계 조사하기



1. Regression

◆ 실전 예제 주요 확인사항

- ✓ 기존의 특성(feature)들 조합하여 새로운 특성 만들기
 - 상호작용 포착
 - 데이터 차원 축소
 - 도메인 지식 활용

1. Regression

◆ 실전 예제 주요 확인사항

✓ Scikit-Learn의 일반적인 설계 철학

- 일관성 : 모든 객체는 일관되고 단순한 인터페이스 공유
 - 추정기^{Estimator} : 데이터셋 기반으로 일련의 모델 파라미터 추정
 - 변환기^{Transformer} : 데이터셋 변환하는 추정기
 - 예측기^{Predictor} : 데이터셋에 대해 예측
- 검사기능 : 모든 추정기의 하이퍼파라미터는 Public 인스턴스 변수로 직접 접근 가능
- 클래스 남용 방지 : 데이터셋은 NumPy배열이나 SciPy의 희소 행렬로 표현
- 조합성 : 기존의 구성 요소를 최대한 재사용
- 합리적인 기본값 : 기본값은 작업에 대한 기본 솔루션을 제공하도록 설정되어 있음

1. Regression

◆ 실전 예제 주요 확인사항

✓ 텍스트와 범주형 특성 다루기

- 대부분의 머신러닝 알고리즘은 숫자를 다룸
- 해결방안
 - `OrdinalEncoding` : 텍스트에서 숫자로 변환 (일반적으로 알파벳 순으로 0번째부터 변환)
 - `One-Hot Encoding` : 텍스트를 이진 특성(0/1)을 만들어 해결

1. Regression

◆ 실전 예제 주요 확인사항

- ✓ 텍스트와 범주형 특성 다루기 : One-Hot Encoding
 - 텍스트를 이진 특성(0/1)을 만들어 해결

	e_1	e_2	e_3
Apple	1	0	0
Banana	0	1	0
Melon	0	0	1

$$e_1 + e_2 + \cdots + e_n = 1$$

1. Regression

◆ 실전 예제 주요 확인사항

✓ 특성 스케일 Feature Scaling


- 입력된 숫자 특성들의 스케일이 많이 다르면 제대로 작동하지 않음
 - 예시) 전체 방 개수의 범위(6 ~ 39,320) ≠ 중간 소득의 범위 (0 ~ 15)
 - 스케일링 미 적용 시, 대부분의 모델은 중간 소득 무시하고 방 개수에 더 초점 맞추기
- 해결방안
 - Min-Max Scaling(=Normalization)
 - Standardization
- 특성 스케일링은 훈련 데이터로만 수행해야 함

1. Regression

◆ 실전 예제 주요 확인사항

✓ 특성 스케일 Feature Scaling : Min-Max Scaling

- 평균이 항상 0이 됨
- 신경망 알고리즘은 평균이 0인 데이터에서 잘 작동하므로 -1 ~ 1사이 범위 선호



1. Regression

◆ 실전 예제 주요 확인사항

✓ 특성 스케일 Feature Scaling : Min-Max Scaling

- 각 특성에 대해서 0 ~ 1 범위에 들도록 값을 이동하고 스케일 조정
- 신경망 알고리즘은 평균이 0인 데이터에서 잘 작동하므로 -1 ~ 1사이 범위 선호
- 이상치에 영향을 받음 (이상치를 1로 지정 해버리고, 나머지는 0~0.15 사이 값으로 처리)

$$\tilde{x} = \frac{x - \min(x)}{\max(x) - \min(x)}$$

1. Regression

◆ 실전 예제 주요 확인사항


- ✓ 특성 스케일 Feature Scaling : **Standardization**
 - 평균은 0, 표준화된 값의 표준 편차는 1이 됨
 - 특정 범위로 값을 제한하지 않음
 - 이상치에 영향을 Min-Max Scaling보다는 덜 받음

1. Regression

◆ 실전 예제 주요 확인사항

- ✓ 특성 스케일 Feature Scaling : **Standardization**

$$\tilde{x} = \frac{x - \text{mean}(x)}{\text{sqrt}(\text{var}(x))}$$



1. Regression

◆ 실전 예제 주요 확인사항


✓ 특성 스케일 Feature Scaling

- 입력된 숫자 특성들의 스케일이 많이 다르면 제대로 작동하지 않음
 - 예시) 전체 방 개수의 범위(6 ~ 39,320) ≠ 중간 소득의 범위 (0 ~ 15)
 - 스케일링 미 적용 시, 대부분의 모델은 중간 소득 무시하고 방 개수에 더 초점 맞추기
- 해결방안
 - Min-Max Scaling(=Normalization)
 - Standardization
 - 로그변환 : 왜도가 심한 경우, 정규분포로 변환해줌
 - 방사 기저 함수 RBF: Radial Basis Function : 멀티모달 분포(정점이 두 개 이상 나타나는 분포)일 때 사용

1. Regression

◆ 실전 예제 주요 확인사항


✓ 모형 자동화 : 파이프라인 적극 사용 (예시)



1. Regression

◆ 실전 예제 주요 확인사항

- ✓ 모델 미세 튜닝 : 만족할 만한 하이퍼파라미터 조합
 - Grid Search : 적은 수의 조합을 탐구할 때, 수동으로 찾기
 - Random Search : 많은 조합을 탐색할 때, 주어진 범위 내에서 자동으로 찾기





1. Regression

실전 예제

2. Classification

◆ 다음 이미지는 어느 레이블에 속해 있는가?



Label	Classes
0	T-shirt/top
1	Trouser
2	Pullover
3	Dress
4	Coat
5	Sandal
6	Shirt
7	Sneaker
8	Bag
9	Ankle boot

2. Classification

◆ 성능평가

- ✓ 혼동행렬, 오차행렬 (Confusion Matrix)
 - TN(True Negative) : 음성을 음성이라고 예측
 - FP(False Positive) : 음성을 양성이라고 예측
 - FN(False Negative) : 양성을 음성이라고 예측
 - TP(True Positive) : 양성을 양성이라고 예측

		예측 결과	
		TRUE	FALSE
실제 정답	TRUE	TP (True Positive)	FN (False Negative)
	FALSE	FP (False Positive)	TN (True Negative)

2. Classification

◆ 성능평가

✓ 혼동행렬, 오차행렬 (Confusion Matrix)

- 불균형 클래스일 때, 정확도는 크게 의미가 없음
 - 양성과 음성의 비율이 9:1이라고 가정할 때, 분류기가 모두 양성이라고 지정하면 90% 정확도 성능을 자랑(?)
- 정확도의 한계점 보완하기 위해 혼동행렬 활용

		예측 결과	
		TRUE	FALSE
실제 정답	TRUE	TP (True Positive)	FN (False Negative)
	FALSE	FP (False Positive)	TN (True Negative)

2. Classification

◆ 성능평가

- ✓ 혼동행렬, 오차행렬 (Confusion Matrix)

		예측 결과	
		TRUE	FALSE
		TRUE	FALSE
실제 정답	TRUE	53892	687
	FALSE	1891	3530

2. Classification

◆ 성능평가

✓ 혼동행렬, 오차행렬 (Confusion Matrix)


- 687개는 ‘양성’이라고 잘못 분류 : 거짓 양성(False Positive) or 1종 오류
- 1891개는 ‘양성이 아니다’라고 잘못 분류 : 거짓 음성(False Negative) or 2종 오류

		예측 결과	
		TRUE	FALSE
실제 정답	TRUE	53892	687
	FALSE	1891	3530

2. Classification

◆ 성능평가

- ✓ 정밀도(Precision)와 재현율(Recall)



2. Classification

◆ 성능평가

✓ 정밀도/재현율 트레이드오프


- 정밀도, 재현율을 모두 높이는 방법은 없음
- 상황에 따라 정밀도가 중요할 수도 있고, 재현율이 중요할 수 있음
- 결정 임계값^{Decision Threshold}의 필요성

2. Classification

◆ 성능평가

✓ 정밀도/재현율 트레이드오프

- 결정 임계값^{Decision Threshold}의 필요성




2. Classification

◆ 성능평가

✓ 정밀도/재현율 트레이드오프

- 좋은 결정 임계값^{Decision Threshold}선택 방법



3. Regularization

◆ 주요 목적 : 과적합^{Overfitting} 방지

✓ 손실 함수에 패널티 추가하여 과적합 방지 기법

- 학습 데이터에서는 잘 작동하지만, 보지 못한 새로운 데이터에서는 성능이 감소
- 모델이 일반화될 수 있도록 도와 새로운 데이터에서의 성능 향상 시킴

✓ 종류


- ✓ L1 정규화^{Regularization} (Lasso Regression)
- ✓ L2 정규화^{Regularization} (Ridge Regression)
- ✓ Elastic Net

3. Regularization

◆ 주요 목적 : 과적합^{Overfitting} 방지

✓ 종류

- β^0 : 아무런 정규화 없이 계산된 최소 제곱 계수
- RSS의 등고선 : 잔차 제곱합의 수준을 나타내며, β 는 최소 제곱값을 의미




3. Regularization

◆ 주요 목적 : 과적합^{Overfitting} 방지

✓ L1 정규화

- 패널티 항목 : LASSO 회귀는 계수의 절대값 합과 동일한 패널티 추가
- 제약 영역 : 주황색 영역은 패널티 항목으로 정의된 제약 영역
 - 절대값 합이 계수 공간에서 다이아몬드 모양을 형성하기 때문에 다이아몬드 모양
- 계수에 미치는 영향
 - 최적의 계수 β 는 RSS 등고선이 다이아몬드 모양의 제약 영역과 맞닿는 지점에서 찾기
- 주요 특징
 - LASSO는 희소성을 유도하여 일부 계수를 정확히 0으로 설정 가능
- 수식

$$L = \sum (y - \hat{y})^2 + \alpha \sum |m|$$




3. Regularization

◆ 주요 목적 : 과적합^{Overfitting} 방지

✓ L2 정규화

- 패널티 항목 : Ridge 회귀는 계수의 제곱값 합과 동일한 패널티 추가
- 제약 영역 : 녹색 원은 패널티 항목으로 정의된 제약 영역
 - 제곱합이 계수 공간에서 원형 영역을 형성하기 때문에 원 모양
- 계수에 미치는 영향
 - 등고선은 잔차 제곱합(RSS)을 나타내며, 최적의 계수 β 는 이 등고선이 제약 영역과 맞닿는 지점에서 찾기
- 주요 특징
 - 계수를 줄이지만, 어떤 계수도 0으로 설정하지 않음, 다중 공선성 방지 및 계수 간의 영향 분산
- 수식



$$L = \sum (y - \hat{y})^2 + \alpha \sum m^2$$

3. Regularization

◆ 주요 목적 : 과적합^{Overfitting} 방지

✓ Elastic Net

- 패널티 항목 : L1 및 L2 패널티 결합
- 제약 영역 : 빨간색 타원은 결합된 패널티 항목으로 정의된 제약 영역
 - 계수 공간에서 원형(L2)과 다이아몬드(L1) 모양을 결합하여 타원형 영역을 형성
- 계수에 미치는 영향
 - 최적의 계수 β 는 RSS 등고선이 타원형 제약 영역과 맞닿는 지점에서 찾기
- 주요 특징
 - Ridge와 LASSO의 절충안을 제공하여 LASSO처럼 희소성 촉진, Ridge처럼 그룹화 효과 유지
- 수식

$$L = \sum (y - \hat{y})^2 + \alpha \sum m^2 + \alpha \sum |m|$$

